

V mailu jsou přiloženy dva datové soubory. První je na úlohy shlukování (neobsahuje informace o třídách) a druhý je pro úlohy klasifikace (obsahuje informace o třídách). V obou případech se jedná o data ve 2D.

- **Shlukování** (data  $[x_i \ y_i]$ )

Cílem je porovnat různé přístupy ke shlukování dat ve 2D prostoru, vyhodnotit jejich vlastnosti, citlivost na parametry.

- 1) Automaticky určete počet tříd v trénovací množině a to několika metodami
  - a) metodou **shlukové hladiny** (automaticky nalezněte hladinu  $h$ )
  - b) metodou **řetězové mapy** (zkuste několik různých počátků)
  - c) metodou **MAXIMIN**metody vzájemně porovnejte (složitost výpočtu).
- 2) Metodou **k-means** rozdělte trénovací data do zjištěného počtu tříd. Porovnejte nerovnoměrné binární dělení s přímým dělením do cílového počtu tříd (velikost kritériální funkce).
- 3) Na výsledném rozdělení dat z bodu 2 vyzkoušet **iterativní optimalizaci**.

- **Klasifikace** (data  $[x_i \ y_i \ \omega_i]$ )

Cílem je analyzovat chování různých klasifikátorů ve 2D, vizualizovat jejich rozhodovací hranice a diskutovat, proč se jednotlivé metody chovají odlišně.

Dostupná data si rozdělte na data trénovací a testovací (90:10). Testovací data použijte pouze na výsledné zhodnocení jednotlivých klasifikátorů. Pokud budete potřebovat u nějaké metody ještě validační data, tak si rozdělte trénovací množinu podle potřeby.


- 4) Na základě informace od učitele (informace o zařazení trénovacích dat do jednotlivých tříd  $\omega_i$ ) natrénujte
  - a) **klasifikátor podle minimální vzdálenosti** - kde každou třídu reprezentujte
    - jejím bodem (středem)
    - více body (použijte kmeans alg.). V tomto případě záleží jen na vás kolik těch vzorových reprezentantů třídy zvolíte.
  - b) **klasifikátor podle nejbližšího souseda** - vyzkoušejte klasifikaci podle jednoho a podle dvou nejbližších sousedů
  - c) **Bayesův klasifikátor** - data v každé třídě popište jednosložkovým normálním rozložením (žádné hledání té hranice (kuželosečky) není třeba)
  - d) **klasifikátor s lineárními diskriminačními funkcemi** - porovnejte potřebný počet iterací při použití Rosenblattova alg., a upravené metody konstantních přírůstků pro několik zvolených konstant učení

- 5) na základě informací od učitele (informace o zařazení trénovacích dat do jednotlivých tříd  $\omega_i$ ) natrénujte jednoduchou **neuronovou síť** pro úlohu klasifikace. Vyzkoušejte
- různé topologie sítě
  - různé způsoby trénování (SGD  $\times$  batch GD)
  - jak se na rychlosti konvergence podílí volba konstanty učení

U každého klasifikátoru vyhodnoťte:

- **přesnost** klasifikace (na testovacích datech)
- **rychlost** trénování
- **vizuální vzhled** rozhodovací hranice

Data jsou záměrně generována ve 2D, aby se to dalo pěkně zobrazit. Chtěl bych obarvit zájmovou oblast (oblast trénovacích dat) podle toho, kam klasifikátor jednotlivé body přiřadí (nebo nepřijadí pokud není schopen). Nejjednodušší postup je projet zájmovou oblast s nějakým dostatečně jemným rastrem a provést klasifikaci.



- jak se hranice mění pro různé přístupy a různé parametry přístupů (např. počtu neuronů, k-NN, atd.).
- kde který z klasifikátorů nefunguje podle představ a proč

Semestrálku můžete řešit v libovolném jazyce. Ale pokud zvolíte nestandardní řešení (mimo Python, Matlab), tak mě raději před odevzdáním informujte, abych se na vás připravil. Pokuste se využívat co nejméně vestavěných funkcí ... není to semestrálka z Pythonu či Matlabu ... je to semestrálka ze strojového učení. Na použité metody se můžu zeptat u zkoušky a předpokládám, že po vyřešení semestrálky budete detailně vědět, jak fungují.

Vaše zjištění prezentujte krátkou zprávou (očekávám spoustu obrázků).